

Practica 3: Selección de Características

Dra. María Elena Martínez Perez
M. en C. Miguel Ángel Veloz Lucas

8 de abril de 2026

1. Reglas generales para el desarrollo de las Prácticas de Laboratorio

- Deberás respetar la estructura general de este documento, i.e, entregar tu práctica con las secciones: objetivos, introducción, desarrollo, código, conclusiones y referencias.
- El desarrollo de la práctica deberá ser auténtico. Aquellos equipos que presenten los mismo cálculos, código fuente, etcétera, serán sancionados.
- El día de entrega establecido deberá ser respetado por todos los equipos. La hora límite de entrega es la hora de clase y no se reciben trabajos que sean terminados durante la hora de clase.
- Deberás entregar el documento en el classroom antes de la fecha límite.

2. Objetivos

- Implementar diferentes métodos de selección de características
- Comparar resultados entre distintos métodos de selección de características.
- Analizar el impacto de la reducción dimensional.

3. Introducción

La selección de características es fundamental en el campo del reconocimiento de patrones y el aprendizaje automático. Su propósito radica en identificar las variables o atributos más informativos dentro de un conjunto de datos, descartando aquellos que son redundantes, irrelevantes o ruidosos. Este proceso no solo mejora la eficiencia computacional, sino que también eleva la capacidad de generalización de los modelos, permitiéndoles identificar patrones subyacentes

evitando el sobreajuste (overfitting). Este proceso, que consiste en identificar el equilibrio entre la simplificación y la optimización, trabajar con menos datos, pero de mayor calidad.

3.1. La Importancia de la Selección de Características

En problemas de alta dimensionalidad, donde el número de características puede superar ampliamente la cantidad de muestras, la selección de estas características se vuelve crítica. Por ejemplo, en imágenes médicas o datos genómicos, es común tener miles de variables, muchas de las cuales pueden ser correlacionadas o carecer de valor predictivo. Al reducir la dimensionalidad, los algoritmos evitan considerar información irrelevante, enfocándose en los atributos clave que definen los patrones. Además, modelos más simples son más interpretables, un aspecto que sobresale en áreas como la medicina o las ciencias sociales, donde entender por qué un modelo toma una decisión es tan importante como su precisión.

3.2. Desafíos y Consideraciones Prácticas

La selección de características continúa teniendo muchos retos. Uno de los más significativos es el manejo de relaciones no lineales o complejas entre variables. Por ejemplo, en problemas de visión artificial, la textura de una imagen puede depender de la interacción no aditiva entre píxeles vecinos, algo que métodos lineales como la correlación podrían pasar por alto. Pero técnicas basadas en métodos no paramétricos (como el análisis de componentes independientes) pueden ser más apropiadas.

Otro desafío es la estabilidad, en donde un conjunto de datos con alto nivel de ruido o muestras limitadas, pueden variar significativamente los subconjuntos seleccionados entre particiones de entrenamiento y validación. Esto afecta a la confiabilidad del modelo, especialmente en aplicaciones críticas como el diagnóstico médico. Para mitigarlo, se recomienda usar técnicas de validación cruzada robustas o métodos de consenso. Adicionalmente, es crucial evitar un enfoque limitado que priorice características individualmente relevantes pero descarte grupos complementarios. Como puede ser el caso del procesamiento de lenguaje natural (NLP), palabras como *no* o *nunca* pueden parecer irrelevantes en un análisis univariado, pero son esenciales para entender el sentimiento negativo cuando se combinan con otros términos.

Por último, el análisis comparativo integra perspectivas estadísticas (pruebas de hipótesis sobre diferencias en precisión y exactitud), computacionales (complejidad de algoritmos) y geométricas (proyecciones en espacios reducidos), ofreciendo una visión más amplia del problema de selección de características en sistemas de reconocimiento de patrones.

4. Desarrollo

Ejercicio : Selección de Características con el Conjunto de datos Wine.

1. Utilizar alguno de los conjuntos de datos propuestos:

Arritmia (*Arrhythmia Database UCI Machine Learning Repository*), el objetivo de este conjunto de datos es diferenciar entre arritmias cardíacas y clasificarlas en uno de los 16 grupos. La clase 01 agrupa a las señales de electrocardiograma (ECG) 'normales', del 02 al 15 a diferentes clases de arritmias y la clase 16 al resto de las señales ECG de arritmias no clasificadas. Cuenta con 452 muestras, 279 características, 206 de las cuales son de valores cuantitativos y el resto cualitativos.

Expresión genética en pacientes con leucemia (*Gene expression dataset from Golub et al. (1999)*), este conjunto de datos consta de 47 pacientes con leucemia linfoblástica aguda (LLA) y 25 pacientes con leucemia mieloide aguda (LMA). A cada uno de los 72 pacientes se le extrajeron muestras de médula ósea al momento del diagnóstico, las mediciones de expresión génica de las muestras resultaron en 7129 características que representan los niveles de expresión de genes para cada muestra. Este conjunto de datos tiene una alta dimensión con pocas muestras, valores con ruido y posible desbalance de clases.

- a) Verificar la integridad del conjunto de datos desde valores faltantes, clases minoritarias con muy pocas muestras, datos atípicos y escalas de datos diferentes (algunas características son frecuencias, otras voltajes).

2. Preparación de Datos

- a) Detectar valores faltantes y completarlos si es el caso.
- b) Aplicar escaladores para remover o mitigar el efecto de muestras atípicas (por ejemplo z-score).
- c) Aplicar técnicas para corregir desbalanceos (como sobremuestreo de la clase minoritaria).
- d) Implementar validación cruzada para evaluar cada método de selección manteniendo un conjunto de prueba separado.
- e) Dividir los datos (80 % entrenamiento / 20 % prueba) sin incluir los datos de prueba en la optimización de parámetros.

3. Implementación de Métodos

- a) **Búsqueda Secuencial hacia delante (SFS)**
 - SFS con validación cruzada e interrupción temprana (*early stopping*) si la exactitud no mejora en 3 iteraciones.

- Generar gráfico exactitud por características (20 mejores características).
 - b) **Fisher**
 - Implementar función del cálculo Score de separabilidad entre clases.
 - Calcular puntuaciones de relevancia de cada característica.
 - Selecciona las 20 características con mayor puntuación.
 - c) **PCA**
 - Remover pares de características altamente correlacionadas (coeficiente > 0.9).
 - Determinar componentes para 95 % varianza.
 - Visualizar proyección 2D.
4. Análisis Comparativo
- a) Crear tabla comparativa con:
 - Método.
 - Características seleccionadas por método.
 - Métricas de entrenamiento y pruebas (exactitud, F1-macro, tiempo de cómputo por método).
 - b) Comentar los mejores resultados.
5. Análisis de resultados
- a) ¿Qué método obtuvo mejor exactitud? ¿Por qué?.
 - b) ¿Qué método es más robusto ante outliers y desbalanceo?
 - c) ¿Cómo afecta la correlación entre características al PCA?.
 - d) ¿Qué ventajas tiene Fisher Score sobre SFS en términos computacionales?.

5. Código

En esta sección deberás presentar el código fuente del programa que hayas escrito.

6. Conclusiones

En esta sección deberás escribir las conclusiones a las que hayas llegado una vez terminada la práctica.

7. Referencias

- Gonzalez, R., Woods, R., Digital Image Processing, Prentice Hall, 2008.
- Pratt, W. k., Digital Image Processing, John Wiley and Sons Inc, 2001.
- Jahne, B., Digital Image Processing, Springer, 2005.
- Sánchez Garreta, Josep Salvador; García, Vicente. Special Issue on Data Preprocessing in Pattern Recognition: Recent Progress, Trends and Applications. 2022.
- Guvenir, H., Acar, B., Muderrisoglu, H., Quinlan, R. (1997). Arrhythmia. UCI Machine Learning Repository. <https://doi.org/10.24432/C5BS32>.
- Golub TR, Slonim DK, Tamayo P, Huard C, Gaasenbeek M, Mesirov JP, Coller H, Loh ML, Downing JR, Caligiuri MA, Bloomfield CD, and Lander ES (1999). Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. Science, 286:531-537.