

Practica 3: Selección de Características

Dra. María Elena Martínez Perez
M. en C. Miguel Ángel Veloz Lucas

8 de abril de 2026

1. Reglas generales para el desarrollo de las Prácticas de Laboratorio

- Deberás respetar la estructura general de este documento, i.e, entregar tu práctica con las secciones: objetivos, introducción, desarrollo, código, conclusiones y referencias.
- El desarrollo de la práctica deberá ser auténtico. Aquellos equipos que presenten los mismo cálculos, código fuente, etcétera, serán sancionados.
- El día de entrega establecido deberá ser respetado por todos los equipos. La hora límite de entrega es la hora de clase y no se reciben trabajos que sean terminados durante la hora de clase.
- Deberás entregar el documento en el classroom antes de la fecha límite.

2. Objetivos

- Implementar diferentes métodos de selección de características
- Comparar resultados entre distintos métodos de selección de características.
- Analizar el impacto de la reducción dimensional.

3. Introducción

La selección de características es fundamental en el campo del reconocimiento de patrones y el aprendizaje automático. Su propósito radica en identificar las variables o atributos más informativos dentro de un conjunto de datos, descartando aquellos que son redundantes, irrelevantes o ruidosos. Este proceso no solo mejora la eficiencia computacional, sino que también eleva la capacidad de generalización de los modelos, permitiéndoles identificar patrones subyacentes

evitando el sobreajuste (overfitting). Este proceso, que consiste en identificar el equilibrio entre la simplificación y la optimización, trabajar con menos datos, pero de mayor calidad.

3.1. La Importancia de la Selección de Características

En problemas de alta dimensionalidad, donde el número de características puede superar ampliamente la cantidad de muestras, la selección de estas características se vuelve crítica. Por ejemplo, en imágenes médicas o datos genómicos, es común tener miles de variables, muchas de las cuales pueden ser correlacionadas o carecer de valor predictivo. Al reducir la dimensionalidad, los algoritmos evitan considerar información irrelevante, enfocándose en los atributos clave que definen los patrones. Además, modelos más simples son más interpretables, un aspecto que sobresale en áreas como la medicina o las ciencias sociales, donde entender por qué un modelo toma una decisión es tan importante como su precisión.

3.2. Desafíos y Consideraciones Prácticas

La selección de características continúa teniendo muchos retos. Uno de los más significativos es el manejo de relaciones no lineales o complejas entre variables. Por ejemplo, en problemas de visión artificial, la textura de una imagen puede depender de la interacción no aditiva entre píxeles vecinos, algo que métodos lineales como la correlación podrían pasar por alto. Pero técnicas basadas en métodos no paramétricos (como el análisis de componentes independientes) pueden ser más apropiadas.

Otro desafío es la estabilidad, en donde un conjunto de datos con alto nivel de ruido o muestras limitadas, pueden variar significativamente los subconjuntos seleccionados entre particiones de entrenamiento y validación. Esto afecta a la confiabilidad del modelo, especialmente en aplicaciones críticas como el diagnóstico médico. Para mitigarlo, se recomienda usar técnicas de validación cruzada robustas o métodos de consenso. Adicionalmente, es crucial evitar un enfoque limitado que priorice características individualmente relevantes pero descarte grupos complementarios. Como puede ser el caso del procesamiento de lenguaje natural (NLP), palabras como *no* o *nunca* pueden parecer irrelevantes en un análisis univariado, pero son esenciales para entender el sentimiento negativo cuando se combinan con otros términos.

Por último, el análisis comparativo integra perspectivas estadísticas (pruebas de hipótesis sobre diferencias en precisión y exactitud), computacionales (complejidad de algoritmos) y geométricas (proyecciones en espacios reducidos), ofreciendo una visión más amplia del problema de selección de características en sistemas de reconocimiento de patrones.

4. Desarrollo

Ejercicio : Selección de Características con el Conjunto de datos Wine.

1. Utilizar alguno de los conjuntos de datos propuestos:

Arritmia (*Arrhythmia Database UCI Machine Learning Repository*), el objetivo de este conjunto de datos es diferenciar entre arritmias cardíacas y clasificarlas en uno de los 16 grupos. La clase 01 agrupa a las señales de electrocardiograma (ECG) 'normales', del 02 al 15 a diferentes clases de arritmias y la clase 16 al resto de las señales ECG de arritmias no clasificadas. Cuenta con 452 muestras, 279 características, 206 de las cuales son de valores cuantitativos y el resto cualitativos.

Expresión genética en pacientes con leucemia (*Gene expression dataset from Golub et al. (1999)*), este conjunto de datos consta de 47 pacientes con leucemia linfoblástica aguda (LLA) y 25 pacientes con leucemia mieloide aguda (LMA). A cada uno de los 72 pacientes se le extrajeron muestras de médula ósea al momento del diagnóstico, las mediciones de expresión génica de las muestras resultaron en 7129 características que representan los niveles de expresión de genes para cada muestra. Este conjunto de datos tiene una alta dimensión con pocas muestras, valores con ruido y posible desbalance de clases.

- a) Verificar la integridad del conjunto de datos desde valores faltantes, clases minoritarias con muy pocas muestras, datos atípicos y escalas de datos diferentes (algunas características son frecuencias, otras voltajes).

Se utilizó el conjunto de datos *Arrhythmia* del UCI Machine Learning Repository. Este conjunto contiene 452 registros y 280 columnas: 279 atributos de entrada y una columna objetivo llamada **Class**. El objetivo es clasificar señales de electrocardiograma en diferentes tipos de arritmia. En los datos cargados se encontraron 13 clases presentes: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 14, 15 y 16.

La distribución original de clases mostró un desbalance importante. Por ejemplo, la clase 1 contiene 245 muestras, mientras que la clase 8 contiene únicamente 2 muestras. Este desbalance justificó el uso de sobremuestreo en el conjunto de entrenamiento.

2. Preparación de Datos

- a) Detectar valores faltantes y completarlos si es el caso.
Primero se cargó el archivo `arrhythmia.data` indicando que el símbolo ? debía tratarse como valor faltante. Los valores faltantes detectados fueron:

Columna	Valores faltantes
T_vector_angle	8
P_vector_angle	22
QRST_vector_angle	1
J_vector_angle	376
Heart_rate	1


La columna **J_vector_angle** fue eliminada porque tenía 376 valores faltantes, equivalentes aproximadamente al 83 % de los registros. Las demás columnas con valores faltantes se imputaron usando la mediana, ya que esta medida es más robusta ante valores atípicos que la media.



- b) Aplicar escaladores para remover o mitigar el efecto de muestras atípicas (por ejemplo z-score).


Se aplicó **RobustScaler** únicamente a las características numéricas continuas. Este escalador usa la mediana y el rango intercuartílico (IQR), por lo que mitiga el efecto de muestras atípicas. Las variables binarias, indicadoras o constantes codificadas como 0/1, por ejemplo **Sex**, **ragged_*** y **diphasic_***, se conservaron sin escalar para mantener su interpretación original.

El tratamiento final fue:

- 197 columnas continuas escaladas con **RobustScaler**.
- 81 columnas binarias/indicadoras conservadas sin escalar.
- 278 columnas predictoras después de eliminar **J_vector_angle**.







- c) Aplicar técnicas para corregir desbalances (como sobremuestreo de la clase minoritaria).

Se utilizó `RandomOverSampler` únicamente sobre el conjunto de entrenamiento. Esta técnica duplica aleatoriamente muestras de las clases minoritarias hasta igualar el número de registros de la clase mayoritaria. En el entrenamiento, cada clase quedó con 196 registros después del sobremuestreo.

El conjunto de prueba no fue sobremuestreado, para mantener una evaluación realista del desempeño del modelo.

```

Conteo de clases en el conjunto de entrenamiento original:
Class
1      196
10     40
2      35
6      20
16     18
3      12
4      12
5      10
9       7
15      4
14      3
7       2
8       2
Name: count, dtype: int64

Conteo de clases en el conjunto de entrenamiento remuestreado:
Class
10     196
6      196
2      196
1      196
16     196
5      196
...
15     196
8      196
14     196
Name: count, dtype: int64

```

- d) Implementar validación cruzada para evaluar cada método de selección manteniendo un conjunto de prueba separado.

Se utilizó validación cruzada estratificada manteniendo separado el conjunto de prueba. Debido a que la clase menos frecuente en el conjunto de entrenamiento original tenía solo 2 muestras, el número de folds efectivos se ajustó a 2. Esto evita errores en **StratifiedKFold**, ya que no se pueden repartir menos muestras reales que el número de folds solicitado.

Durante la validación cruzada, el sobremuestreo se aplicó solamente dentro del fold de entrenamiento. El fold de validación se mantuvo sin sobremuestrear para evitar fuga de información.

- e) Dividir los datos (80 % entrenamiento / 20 % prueba) sin incluir los datos de prueba en la optimización de parámetros.

Los datos fueron divididos de acuerdo a este criterio.

3. Implementación de Métodos

a) **Búsqueda Secuencial hacia delante (SFS)**

- SFS con validación cruzada e interrupción temprana (*early stopping*) si la exactitud no mejora en 3 iteraciones.
- Generar gráfico exactitud por características (20 mejores características).


La búsqueda secuencial hacia delante se implementó agregando en cada paso la característica que más incrementaba el criterio multivariado de separabilidad de Fisher. El proceso se detuvo al alcanzar un máximo de 20 características o cuando el puntaje Fisher no mejoró durante 3 iteraciones consecutivas.


En cada fold de validación cruzada, SFS se ejecutó solo con los datos de entrenamiento del fold. Posteriormente se entrenó el modelo con las características seleccionadas y se evaluó en el fold de validación. El ajuste final seleccionó 20 características, entre ellas:

- V3_Q_wave_width
- V6_R_wave_width
- V4_QRSA
- PR_interval
- V3_diphasic_P_wave
- Sex

El resultado en prueba para SFS fue:

Métrica	Valor
Exactitud	0.5824
Precisión macro	0.2413
Recall macro	0.2758
F1 macro	0.2323
Tiempo	18.6947 s





b) Fisher


- Implementar función del cálculo Score de separabilidad entre clases.
- Calcular puntuaciones de relevancia de cada característica.
- Selecciona las 20 características con mayor puntuación.

El método Fisher Score evaluó cada característica de forma individual mediante la razón entre dispersión interclase e intraclase. Después se seleccionaron las 20 características con mayor puntuación. Las principales características seleccionadas fueron:

- V3_Q_wave_width
- DI_R_wave_width
- V6_R_wave_width
- V3_S_wave_width
- V2_JJ_wave_amplitude
- PR_interval
- Heart_rate

El resultado en prueba para Fisher fue:

Métrica	Valor
Exactitud	0.6154
Precisión macro	0.2478
Recall macro	0.3116
F1 macro	0.2644
Tiempo	2.0093 s



c) PCA


- Remover pares de características altamente correlacionadas (coeficiente > 0.9).
- Determinar componentes para 95 % varianza.
- Visualizar proyección 2D.


Antes de aplicar PCA se removieron pares de características altamente correlacionadas con coeficiente absoluto mayor a 0.9. De las 278 características originales, se eliminaron 31 por alta correlación y se conservaron 247 para PCA.

Después, PCA determinó el número de componentes necesario para explicar al menos el 95 % de la varianza. El ajuste final requirió 14 componentes principales.

El resultado en prueba para PCA fue:

Métrica	Valor
Exactitud	0.5934
Precisión macro	0.2672
Recall macro	0.3420
F1 macro	0.2924
Tiempo	3.1073 s





4. Análisis Comparativo

a) Crear tabla comparativa con:

- Método.
- Características seleccionadas por método.
- Métricas de entrenamiento y pruebas (exactitud, F1-macro, tiempo de cómputo por método).

Método	Variables/Comp.	Acc. CV	Std. CV	Acc. prueba	Prec. macro	Recall macro	F1 macro
Fisher	20	0.6094	0.0017	0.6154	0.2478	0.3116	0.2644
PCA	14	0.5540	0.0206	0.5934	0.2672	0.3420	0.2924
SFS	20	0.5679	0.0043	0.5824	0.2413	0.2758	0.2323

b) Comentar los mejores resultados.

El método con mayor exactitud en el conjunto de prueba fue Fisher Score, con una exactitud de 0.6154. También fue el método más estable en validación cruzada, pues obtuvo la menor desviación estándar entre folds (0.0017). PCA obtuvo el mejor F1 macro (0.2924), lo que sugiere que, aunque su exactitud fue menor que la de Fisher, tuvo un mejor equilibrio promedio entre clases.

SFS obtuvo una exactitud menor y fue el método con mayor tiempo de cómputo. Esto es esperado, ya que evalúa subconjuntos de características de manera secuencial y el cálculo multivariado de Fisher requiere más operaciones que el Fisher Score univariado.

5. Análisis de resultados

a) ¿Qué método obtuvo mejor exactitud? ¿Por qué?.

El método con mejor exactitud fue Fisher Score, con 0.6154 en el conjunto de prueba. Esto puede explicarse porque varias características individuales del ECG presentaron alta separabilidad entre clases. Al seleccionar las 20 variables con mayor relación entre dispersión interclase e intraclase, Fisher conservó información discriminante suficiente sin introducir tanta complejidad.

b) ¿Qué método es más robusto ante outliers y desbalanceo?

El preprocesamiento más robusto ante outliers fue el escalamiento con **RobustScaler**, ya que utiliza mediana e IQR. Respecto al desbalanceo, la robustez provino del uso de **RandomOverSampler** en entrenamiento y de **class_weight="balanced"** en el modelo Random Forest. Entre los métodos comparados, Fisher fue el más estable según la desviación estándar de validación cruzada.

c) ¿Cómo afecta la correlación entre características al PCA?

La correlación alta entre características puede provocar redundancia: varias variables contienen información muy similar. PCA combina variables correlacionadas en componentes principales, pero si hay demasiada redundancia, algunas características pueden aportar poca información nueva. Por ello se removieron pares con correlación mayor a 0.9 antes de aplicar PCA. Esto redujo la dimensionalidad de 278 a 247 características antes de obtener los componentes principales.

d) ¿Qué ventajas tiene Fisher Score sobre SFS en términos computacionales?

Fisher Score es más eficiente porque evalúa cada característica por separado una sola vez y después ordena los puntajes. En cambio, SFS evalúa múltiples subconjuntos de características en cada iteración, lo cual aumenta considerablemente el costo computacional. En los resultados obtenidos, Fisher tardó 2.0093 segundos, mientras que SFS tardó 18.6947 segundos.

5. Código

Se adjunta el archivo.ipynb

6. Conclusiones

En esta práctica se implementaron y compararon tres métodos de selección o reducción de características aplicados al conjunto de datos de arritmias. Se observó que el preprocesamiento fue una etapa crítica debido a la presencia de valores faltantes, clases desbalanceadas, variables continuas, variables binarias y valores atípicos.

Fisher Score obtuvo la mejor exactitud en prueba y la mayor estabilidad en validación cruzada. PCA obtuvo el mejor F1 macro, lo que indica un mejor balance promedio entre clases, aunque con menor exactitud que Fisher. SFS permitió evaluar subconjuntos de características, pero tuvo mayor costo computacional y no superó a Fisher en este experimento.

Finalmente, el uso de `RobustScaler`, `RandomOverSampler`, validación cruzada estratificada y un conjunto de prueba separado permitió realizar una comparación más controlada entre métodos, evitando que los datos de prueba influyeran en la selección de características o en el ajuste del modelo.

7. Referencias

- Gonzalez, R., Woods, R., Digital Image Processing, Prentice Hall, 2008.
- Pratt, W. k., Digital Image Processing, John Wiley and Sons Inc, 2001.
- Jahne, B., Digital Image Processing, Springer, 2005.
- Sánchez Garreta, Josep Salvador; García, Vicente. Special Issue on Data Preprocessing in Pattern Recognition: Recent Progress, Trends and Applications. 2022.
- Guvenir, H., Acar, B., Muderrisoglu, H., Quinlan, R. (1997). Arrhythmia. UCI Machine Learning Repository. <https://doi.org/10.24432/C5BS32>.
- Golub TR, Slonim DK, Tamayo P, Huard C, Gaasenbeek M, Mesirov JP, Coller H, Loh ML, Downing JR, Caligiuri MA, Bloomfield CD, and Lander ES (1999). Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. Science, 286:531-537.