

Practica 4: Clasificadores

Dra. María Elena Martínez Perez
M. en C. Miguel Ángel Veloz Lucas

29 de abril de 2026

1 Reglas generales para el desarrollo de las Prácticas de Laboratorio

- Deberás respetar la estructura general de este documento, i.e, entregar tu práctica con las secciones: objetivos, introducción, desarrollo, código, conclusiones y referencias.
- El desarrollo de la práctica deberá ser auténtico. Aquellos equipos que presenten los mismos cálculos, código fuente, etcétera, serán sancionados.
- El día de entrega establecido deberá ser respetado por todos los equipos. La hora límite de entrega es la hora de clase y no se reciben trabajos que sean terminados durante la hora de clase.
- Deberás entregar el documento en el classroom antes de la fecha límite.

2 Objetivos

En esta práctica avanzaremos en el uso de cuatro clasificadores supervisados sobre distintos conjuntos de datos. Cada ejercicio incluye:

- Preprocesamiento de datos.
- Reducción de dimensionalidad PCA y visualización en 2D/3D.
- Búsqueda e interpretación de hiperparámetros.
- Análisis de resultados.

3 Introducción

3.1 Tipos de Clasificadores para Reconocimiento de Patrones

El reconocimiento de patrones es una disciplina fundamental en inteligencia artificial y aprendizaje automático, cuyo objetivo es identificar regularidades o

estructuras en datos para asignarles categorías. Los clasificadores son algoritmos que implementan esta tarea, y su elección depende de factores como la naturaleza de los datos, la complejidad del problema y la necesidad de interpretabilidad. A continuación, se describen los principales tipos de clasificadores y sus características.

3.2 Clasificadores No Lineales

Cuando los datos presentan relaciones complejas, se emplean modelos no lineales. Los árboles de decisión son un ejemplo: dividen recursivamente el espacio de características mediante reglas jerárquicas, lo que los hace interpretables pero propensos al sobreajuste. Otro enfoque es el algoritmo k-vecinos más cercanos (kNN), que clasifica instancias según la mayoría de clases entre sus vecinos más cercanos. Aunque es flexible y no requiere entrenamiento explícito, su costo computacional crece con el tamaño de los datos. Estos métodos son útiles en reconocimiento de escritura manual o sistemas de recomendación basados en similitud.

3.3 Clasificadores Probabilísticos

Basados en teoría de probabilidad, estos modelos estiman distribuciones para predecir clases. El clasificador Naive Bayes es el más conocido: asume independencia entre características y aplica el teorema de Bayes para calcular probabilidades. Aunque simplista, es eficaz en datos categóricos o textuales, como en análisis de sentimientos o detección de spam. Las redes Bayesianas, por otro lado, modelan dependencias entre variables, ofreciendo mayor flexibilidad a costa de complejidad.

3.4 Máquinas de Soporte Vectorial (SVM)

Las SVM buscan hiperplanos óptimos para separar clases, incluso en espacios de alta dimensión. En su versión lineal, maximizan el margen entre clases, mientras que con *kernels* transforman los datos a espacios donde la separación no lineal es posible. Son eficaces en reconocimiento facial o clasificación de imágenes médicas, pero requieren ajuste de parámetros y normalización de datos.

3.5 Redes Neuronales

Estos modelos, inspirados en el cerebro humano, destacan por su capacidad para aprender patrones complejos. Los perceptrones multicapa (MLP) son redes *feed-forward* con capas ocultas no lineales, mientras que las redes convolucionales (CNN) se especializan en datos *grid-like* (como imágenes). Las redes recurrentes (RNN) manejan secuencias (texto, series temporales). Aunque son extremadamente poderosas (ej. en visión por computadora o traducción automática), requieren grandes volúmenes de datos, recursos computacionales y carecen de interpretabilidad.

4 Desarrollo

Ejercicio: Aplicación y comparación de clasificadores.

Selecciona tres conjuntos de datos para entrenar distintos modelos de clasificación variando la configuración de sus hiperparámetros. En el desarrollo del notebook se trabajó con dos conjuntos de datos: *Breast Cancer Wisconsin Diagnostic* y *Parkinsons Telemonitoring*. El primero es un problema de clasificación binaria y el segundo fue adaptado de regresión a clasificación mediante la creación de una variable de severidad.

Conjunto de datos propuesto:

- Clasificación Multimodelo para Cáncer de Mama (*Breast Cancer Wisconsin Diagnostic*): Conjunto de datos biomédicos que contiene características numéricas derivadas de imágenes digitales de aspiraciones con aguja fina (FNA) de masas mamarias, utilizadas para clasificar tumores como benignos o malignos.
- Detección Temprana de Parkinson, voz y biomarcadores acústicos (*Parkinsons Telemonitoring*): Conjunto de datos con medidas biomédicas de voz y variables clínicas UPDRS. Aunque originalmente está orientado a regresión, se transformó a clasificación mediante clases de severidad.

1. Carga y análisis de datos:

(a) Cargar el conjunto de datos.

Breast Cancer contiene 569 registros y 32 columnas. La variable objetivo es `diagnosis`, con clases B para benigno y M para maligno. Parkinsons contiene 5875 registros y 22 columnas. Como este conjunto contiene originalmente `motor_UPDRS` y `total_UPDRS` como variables continuas, se creó la clase `updrs_severity` a partir de terciles de `total_UPDRS`. Posteriormente, `motor_UPDRS`, `total_UPDRS` y `subject#` se excluyeron de las variables predictoras para evitar fuga de información.

Dataset	Dimensiones	Variable objetivo	Clases
Breast Cancer	569 x 32	<code>diagnosis</code>	B, M
Parkinsons	5875 x 22	<code>updrs_severity</code>	low, medium, high

Table 1: Resumen de los conjuntos de datos utilizados.

(b) Visualización de la distribución de clases.

Breast Cancer presentó 357 casos benignos y 212 malignos, por lo que existe un desbalance moderado. Parkinsons quedó prácticamente balanceado después de construir las clases por terciles: 1961 casos low, 1956 medium y 1958 high.

Clase	Frecuencia
Breast Cancer B	357
Breast Cancer M	212
Parkinsons low	1961
Parkinsons medium	1956
Parkinsons high	1958

Table 2: Distribución de clases por conjunto de datos.

Placeholder de imagen: distribución de clases de Breast Cancer y Parkinsons.

Figure 1: Distribución de clases por conjunto de datos.

- (c) Análisis de valores faltantes (porcentaje de valores faltantes por columna).
No se encontraron valores faltantes en ninguno de los dos conjuntos de datos. Por esta razón, no fue necesario imputar valores en la etapa de limpieza.

2. Preprocesamiento y limpieza:

- (a) Separación de tipos de variables (Identificamos columnas numéricas y categóricas).

En Breast Cancer se descartaron `id` y `diagnosis`; quedaron 30 variables numéricas como predictores. En Parkinsons se descartaron `subject#`, `motor_UPDRS`, `total_UPDRS` y `updrs_severity`; quedaron 19 variables numéricas.

- (b) Verificar y aplicar limpieza de datos (faltantes, *outliers*, caracteres inválidos, etc.).

Dado que no había valores faltantes, no se aplicó imputación. Sí se detectaron valores atípicos mediante la regla IQR. En Breast Cancer destacaron `se_area` (65), `se_radius` (38), `se_perimeter` (38), `worst_area` (35) y `se_smoothness` (30). En Parkinsons destacaron `NHR` (436), `Jitter:PPQ5` (425), `Jitter:RAP` (414), `Jitter:DDP` (413) y `Jitter(%)` (398).

Placeholder de imagen: barras con variables con más *outliers* por IQR.

Figure 2: Variables con mayor cantidad de valores atípicos detectados por IQR.

- (c) Estandarización de características (escaladores).

Se utilizó `RobustScaler` en ambos conjuntos, ya que este escalador usa mediana y rango intercuartílico, lo cual reduce la influencia de valores extremos frente a `StandardScaler`.

- (d) Separación en 70% entrenamiento y 30% prueba.

La división fue estratificada. Breast Cancer quedó con 398 registros de entrenamiento y 171 de prueba. En entrenamiento tuvo 250 casos B y 148 M. Parkinsons quedó con 4112 registros de entrenamiento y 1763 de prueba. En entrenamiento tuvo 1373 casos **low**, 1370 **high** y 1369 **medium**.

- (e) Manejo del desbalance de clases sobre el conjunto de entrenamiento (por ejemplo SMOTE, ADASYN o Sobremuestreo aleatorio).

Para Breast Cancer se aplicó SMOTE porque la razón minoría/mayoría fue 0.592; la clase maligna pasó de 148 a 250 muestras en entrenamiento. En Parkinsons no se aplicó SMOTE porque las clases quedaron prácticamente balanceadas, con razón minoría/mayoría de 0.997.

- (f) Visualización de la distribución.

La distribución posterior al manejo de desbalance se verificó para confirmar el balance aplicado en Breast Cancer y la conservación de clases en Parkinsons.

3. Reducción de dimensionalidad por análisis de componentes principales (PCA):

- (a) Aplicar PCA a los datos balanceados.

PCA se aplicó después del escalado robusto. En Breast Cancer se usaron los datos con SMOTE dentro del flujo de entrenamiento; en Parkinsons se usaron los datos sin remuestreo.

- (b) Cálculo de la varianza acumulada.

En Breast Cancer, el primer componente explicó 44.59% de la varianza y los dos primeros 64.69%. En Parkinsons, el primer componente explicó 77.73% y los dos primeros 86.94%.

- (c) Encontrar el número de componentes para el 95% de varianza.

Breast Cancer necesitó 10 componentes para alcanzar 0.9591 de varianza acumulada. Parkinsons necesitó 6 componentes para alcanzar 0.9598.

Dataset	Componentes	Varianza acumulada
Breast Cancer	10	0.9591
Parkinsons	6	0.9598

Table 3: Componentes necesarios para conservar al menos el 95% de la varianza.

- (d) Gráfico del número de componentes principales y varianza acumulada.

4. Definición de modelos, esquema de trabajo y búsqueda en cuadrícula (grid search):

Placeholder de imagen: curvas de varianza acumulada PCA para ambos conjuntos.

Figure 3: Varianza acumulada en función del número de componentes principales.

- (a) Desarrollar un esquema de funciones (*pipelines*) que integren el pre-procesamiento y el clasificador.

Se construyeron *pipelines* con escalado robusto, manejo de desbalance cuando correspondía, PCA y clasificador. Los modelos evaluados fueron KNN, árbol de decisión y SVM.

- (b) La búsqueda en cuadrícula nos permitirá encontrar los mejores hiperparámetros.

La búsqueda se realizó con `GridSearchCV`, validación cruzada de 3 pliegues y métrica `f1_macro`. Esta métrica fue elegida porque pondera por igual el desempeño de todas las clases.

5. Configuración de modelos y cuadro de hiperparámetros

- (a) Modelo de KNN:

- vecinos (1,3,5,7,9).
- pesos (*weights*: ['uniform', 'distance']).
- distancia (*metric*: ['euclidean', 'manhattan']).

En Breast Cancer el mejor KNN usó distancia Manhattan, 7 vecinos y pesos uniformes. En Parkinsons el mejor KNN usó distancia Manhattan, 9 vecinos y pesos por distancia.

- (b) Modelo de árbol de decisión

- profundidad ([3, 5, 7, None]).
- número mínimo de muestras por división (*samples split*: [2, 5, 10]).
- criterio de división (*criterion*: ['gini', 'entropy']).
- peso de clases (*class_weight*: [None, 'balanced']).

En Breast Cancer el mejor árbol usó criterio *entropy*, profundidad 5, `min_samples_split=10` y sin ponderación de clases. En Parkinsons el mejor árbol usó *entropy*, profundidad sin límite, `min_samples_split=10` y `class_weight='balanced'`.

- (c) Modelo de SVM

- kernel (['linear', 'rbf']).
- Regularización C (0.1, 1, 10).
- Gamma (['scale', 'auto', 0.01, 0.1]).
- peso de clases (*class_weight*: [None, 'balanced']).

En Breast Cancer el mejor SVM usó *kernel* RBF, `C=1`, `gamma=scale` y sin ponderación de clases. En Parkinsons el mejor SVM usó *kernel* RBF, `C=10`, `gamma=auto` y sin ponderación de clases.

6. Entrenamiento, evaluación y comparación de resultados:

- (a) Mejores métricas de rendimiento sobre conjunto de prueba por conjunto de datos.

Dataset	Modelo	F1 CV	Accuracy	Balanced acc.	F1 macro
Breast Cancer	SVM	0.9674	0.9942	0.9922	0.9937
Breast Cancer	KNN	0.9671	0.9825	0.9766	0.9811
Breast Cancer	Árbol	0.9304	0.9474	0.9360	0.9429
Parkinsons	SVM	0.6149	0.6557	0.6556	0.6526
Parkinsons	KNN	0.6339	0.6529	0.6528	0.6524
Parkinsons	Árbol	0.6373	0.6478	0.6478	0.6477

Table 4: Comparación de rendimiento en el conjunto de prueba.

- (b) Matriz de confusión de los modelos entrenados con las mejores métricas.

En Breast Cancer, SVM fue el mejor modelo y cometió únicamente un error relevante sobre prueba: un caso maligno fue clasificado como benigno. En Parkinsons, SVM también fue el mejor en prueba, pero la clase `medium` fue la más difícil de identificar.

Placeholder de imagen: matrices de confusión para Breast Cancer y Parkinsons.

Figure 4: Matrices de confusión de los modelos entrenados.

- (c) Mostrar las fronteras de decisión superponiendo datos de entrenamiento y prueba.

Placeholder de imagen: fronteras de decisión en PCA 2D para los mejores modelos.

Figure 5: Fronteras de decisión usando dos componentes principales.

- (d) Mostrar el árbol entrenado con los mejores parámetros.

Placeholder de imagen: primeros niveles del árbol de decisión entrenado.

Figure 6: Árbol de decisión entrenado con los mejores hiperparámetros.

(e) Comparar exactitud entre modelos.

En Breast Cancer, SVM obtuvo la mayor exactitud (0.9942), seguido por KNN (0.9825) y árbol de decisión (0.9474). En Parkinsons, SVM también obtuvo la mayor exactitud (0.6557), aunque KNN fue muy cercano (0.6529) y el árbol alcanzó 0.6478.

(f) ¿Qué hiperparámetro fue más relevante por modelo para cada conjunto de datos?

En Breast Cancer, los hiperparámetros más relevantes fueron `criterion` para árbol de decisión, `n_neighbors` para KNN y `C` para SVM. En Parkinsons fueron `max_depth` para árbol de decisión, `n_neighbors` para KNN y `kernel` para SVM.

5 Código

Por indicación del reporte, no se incluye el código fuente en esta sección. El análisis, los experimentos y las salidas utilizadas para elaborar este documento se encuentran en el archivo `notebook.ipynb`.

6 Conclusiones

La comparación entre clasificadores mostró comportamientos distintos para cada conjunto de datos. En Breast Cancer, todos los modelos lograron un desempeño alto, pero SVM fue el mejor con una exactitud de 0.9942 y F1 macro de 0.9937. Esto sugiere que las características geométricas extraídas de las imágenes FNA contienen información altamente discriminante para separar tumores benignos y malignos.

En Parkinsons, el desempeño fue más moderado. El mejor modelo en prueba también fue SVM, con exactitud de 0.6557 y F1 macro de 0.6526. La dificultad principal apareció en la clase de severidad media, debido a que la etiqueta se generó a partir de cortes sobre una variable continua. Esta clase representa una zona intermedia donde las señales acústicas pueden solaparse con las clases baja y alta.

El uso de `RobustScaler` fue adecuado porque ambos conjuntos presentaron valores atípicos. Además, SMOTE fue útil únicamente para Breast Cancer, donde sí existía desbalance de clases. Para Parkinsons no fue necesario, ya que la construcción por terciles produjo clases casi equivalentes. Finalmente, PCA permitió reducir la dimensionalidad conservando más del 95% de la varianza: 10 componentes en Breast Cancer y 6 componentes en Parkinsons.

7 Referencias

- Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1993). *Breast Cancer Wisconsin (Diagnostic)* [Dataset]. UCI Machine Learning Repos-

itory. <https://doi.org/10.24432/C5DW2B>.

- Tsanas, A. & Little, M. (2009). *Parkinsons Telemonitoring* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5ZS3N>.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. *Journal of Machine Learning Research*, 18(17), 1–5.
- Murphy, Kevin P. *Machine learning: a probabilistic perspective*. MIT press, 2012.