


RECONOCIMIENTO DE PATRONES

Impartido por: Elena Martínez
Departamento de Ciencias de la Computación
IIMAS, UNAM, cubículo 408
elena.martinez@iimas.unam.mx



Curso de Reconocimiento de Patrones

1. Introducción
2. Extracción de características
3. Selección de características
4. Clasificación
5. Evaluación de desempeño
6. Agrupamiento

Capítulo 6. Clustering

1. **Introducción**
2. Métodos de Partición (K-means)
3. Métodos Basados en Densidad y Centroides (Mean Shift)
4. Métodos Basados en Modelos (Gaussian Mixture Models)
5. Métodos Jerárquicos (Hierarchical Clustering)
6. Bolsa de palabras (Bag of Words)

Introducción al Agrupamiento (Clustering)

1. **Clasificación supervisada:** es una técnica en la que un modelo aprende a categorizar datos en grupos o clases distintos basándose en ejemplos de entrenamiento etiquetados. Este proceso implica proporcionar al modelo un conjunto de datos donde cada muestra está asociada a una etiqueta de clase conocida (entrada), lo que le permite aprender las relaciones entre las características de entrada y sus correspondientes clases de salida. Una vez entrenado, el modelo puede utilizarse para predecir la etiqueta de clase de datos nuevos e inéditos.
2. **Clasificación no-supervisada:** es una técnica en la que los algoritmos agrupan automáticamente los datos en clases según sus similitudes y diferencias inherentes, sin depender de datos de entrenamiento pre-etiquetados. La clasificación no supervisada es útil para el análisis exploratorio de datos, el descubrimiento de patrones ocultos y la identificación de agrupaciones naturales en los datos. El algoritmo aprende de los datos sin procesar sin que se le enseñe explícitamente qué clases reconocer. En esencia, la clasificación no supervisada potencia el análisis de datos al permitir el descubrimiento de estructuras y patrones ocultos sin la necesidad de datos previamente etiquetados, lo que la convierte en una herramienta valiosa para diversas aplicaciones.

Técnicas de Agrupamiento (Clustering)

- Consisten en métodos de **aprendizaje automático no supervisado** que organizan un conjunto de datos en grupos (clústeres) homogéneos, de manera que los elementos dentro de un mismo grupo sean más similares entre sí que con los de otros grupos. El objetivo principal es descubrir estructuras, patrones ocultos o segmentos naturales en los datos sin tener etiquetas previas.

En qué se basan estas técnicas

- **Medición de Similitud:** Utilizan funciones de distancia (como la distancia euclideana) para calcular la proximidad entre los datos.
- **Homogeneidad Interna:** Buscan minimizar la distancia entre los puntos de un mismo clúster.
- **Separación Externa:** Buscan maximizar la distancia o diferencia entre los diferentes clústeres.
- **Aprendizaje No Supervisado:** A diferencia de la clasificación, aquí no se conoce de antemano el grupo al que pertenece cada dato; el algoritmo lo descubre.



Capítulo 6. Clustering

1. Introducción
2. Métodos de Partición (K-means)
3. Métodos Basados en Densidad y Centroides (Mean Shift)
4. Métodos Basados en Modelos (Gaussian Mixture Models)
5. Métodos Jerárquicos (Hierarchical Clustering)
6. Bolsa de palabras (Bag of Words)



Algoritmo K-means

Algoritmo:



1. Datos de entrada: $X = \{x_1, x_2, \dots, x_N\}$ y número de cúmulos K
2. Centroides $\{c_1, c_2, \dots, c_K\} = K$ puntos aleatorios de X
3. Para cada punto x_i
4. Calcula la distancia $d_{ij} = d(x_i, c_j) \quad i=1, \dots, N, j=1, \dots, K$
5. Asigna x_i al centroide más cercano: $y_i = \operatorname{argmin}_j \{d_{ij}\}$
6. Calcula el nuevo centroide para cada cúmulo
 $c_j^* = \operatorname{mean}(x_i) \text{ for } y_i = j$
7. if $c_j^* \neq c_j$ then $c_j = c_j^*$ ve al paso 3
8. Salida: $\{c_1^*, c_2^*, \dots, c_K^*\}$ y y_i for $i=1, \dots, N$




Elegir $K=2$ puntos al azar (centroides)




Asignar al centroide más cercano





Asignar al centroide más cercano




Asignar al centroide más cercano




Calcular los centroides







Asignar al centroide más cercano



Asignar al centroide más cercano

Repetir hasta converger




Algoritmo:


1. Datos de entrada: $X = \{x_1, x_2, \dots, x_N\}$ y el número de cúmulos K
2. Centroides $\{c_1, c_2, \dots, c_K\} = K$ puntos aleatorios de X
3. Para cada punto x_i
4. Calcular la distancia $d_{ij} = d(x_i, c_j)$ $i=1, \dots, N, j=1, \dots, K$
5. Asignar x_i al centroide más cercano: $y_i = \operatorname{argmin}_j \{d_{ij}\}$
6. Calcular el nuevo centroide de cada cúmulo
 $c_j^* = \operatorname{mean}(x_i) \text{ for } y_i = j$
7. if $c_j^* \neq c_j$ then $c_j = c_j^*$ ir al paso 3
8. Salida: $\{c_1^*, c_2^*, \dots, c_K^*\}$ y y_i para $i=1, \dots, N$

Exemplo: Dos Nubes de Puntos


Dato de entrada




Iteración 0:




Iteración 1:




Iteración 1:




Iteración 2:




Iteración 3:




Iteración 4:




Iteración 5:



Cúmulos Encontrados




Datos de entrada




Exemplo: Segmentación a Color




Segmentación por Clustering




Segmentación por Clustering




Segmentación por Clustering




Segmentación por Clustering




Algoritmo



Clustering usando k-means





INPUT



OUTPUT



¿PREGUNTAS?

Impartido por: Elena Martínez

Departamento de Ciencias de la Computación

IIMAS, UNAM, cubículo 408

elena.martinez@iimas.unam.mx